Satya auf Celo

Herkunft von Inhalten als öffentliches Register – jede Aussage an genau einen Menschen gebunden.

satya (सत्य) ist Sanskrit für Wahrheit – nicht als Behauptung, sondern als etwas, für das jemand einsteht.

Eingereicht für *Agents on Open Rails* (Celo). Live auf Celo Sepolia, verifiziert, mit echten Transaktionen.

Vertrag	`0x58d5f2c2ac866D7828b7e2Bf1A3542C3536c3001` (Quellcode verifiziert)
Netz	Celo Sepolia (11142220)
Bezahlter Endpunkt	`POST /api/x402/verify` · 0,01 USDC je Anfrage
Agentenprofil	`/.well-known/agent.json`, ERC-8004 agentId **453**
Tests	29 Vertragstests + 20 Python-Tests, alle grün

---

1. Das Problem, ehrlich benannt

Die Frage „Hat eine KI das geschrieben?" lässt sich **nicht zuverlässig am Inhalt selbst beantworten**. Das ist kein Werkzeugmangel, sondern ein bewiesenes Ergebnis: Sadasivan et al. zeigen, dass die Erkennbarkeit mit besseren Modellen gegen den Zufall konvergiert; Zhang et al. zeigen, dass starke Wasserzeichen unter realistischen Annahmen nicht existieren können. Jeder Detektor, der ein Urteil aus Stil oder Statistik ableitet, produziert Fehlalarme – und trifft dabei systematisch Nicht-Muttersprachler.

Gleichzeitig greift ab August 2026 Artikel 50 der KI-Verordnung: KI-Anbieter müssen ihre Ausgaben maschinenlesbar kennzeichnen. Es entsteht also eine Welt, in der **Herkunft erklärt wird**, statt erraten zu werden.

Satya zieht daraus die Konsequenz:

> Nicht raten, wer etwas geschrieben hat – sondern festhalten, **wer sich dafür verbürgt**, und was passiert, wenn jemand lügt.

2. Was auf Celo neu ist

Die bestehende Prüfschicht (C2PA gegen die offizielle Trust List, Metadaten, Wasserzeichen, Siegel) beantwortet: *Was behauptet die Datei über sich selbst?* Sie beantwortet **nicht**: *Wer haftet dafür, und ist das derselbe, der gestern das Gegenteil sagte?*

Genau das löst der Vertrag auf Celo – mit drei Eigenschaften, die ohne Celo nicht möglich wären:

a) Eine Person, eine Stimme – nicht eine Wallet, eine Stimme

Jede Erklärung wird über **Self Agent ID** an den ZK-Nullifier eines echten Ausweises gebunden. Wallets sind beliebig vermehrbar, Menschen nicht.

Das ist kein theoretisches Argument. Live auf Celo Sepolia ausgelesen:

Self agentId	Wallet	Nullifier
1	`0x5517…e47a`	`105325254507…0982`
2	`0x5E25…Ab95`	**derselbe**
3	`0x5E25…Ab95`	**derselbe**

Drei Agenten, zwei Wallets, **ein Mensch**. In einem naiven Register hätte diese Person drei Stimmen. Satya zählt eine – `declareAsHuman` lehnt die zweite Erklärung desselben Nullifiers zum selben Inhalt ab.

b) Lügen sind widerlegbar – von jedem, ohne Betreiber

Wenn dieselbe Person über denselben Inhalt zwei unvereinbare Aussagen macht („von mir allein" und „von KI erzeugt"), kann **jeder Beliebige** das beweisen:

```
proveSelfContradiction(contentHash, indexA, indexB)
```

Der Vertrag prüft nur Nullifier-Gleichheit und Unvereinbarkeit. Beide Aussagen werden dauerhaft als `disputed` markiert; `provenFraud` wird gesetzt. Es gibt keinen Admin, der das entscheidet, und keinen, der es verhindern kann. **Der Vertrag hat keinen Eigentümer** – nach dem Deployment gibt es keine privilegierte Rolle mehr.

Das verwandelt ein Vertrauensproblem in ein Rechenproblem: Eine Lüge bleibt billig, aber sie wird **dauerhaft nachweisbar**, und das Register vergisst sie nie.

c) Der Dienst bezahlt sich selbst – ohne Konto

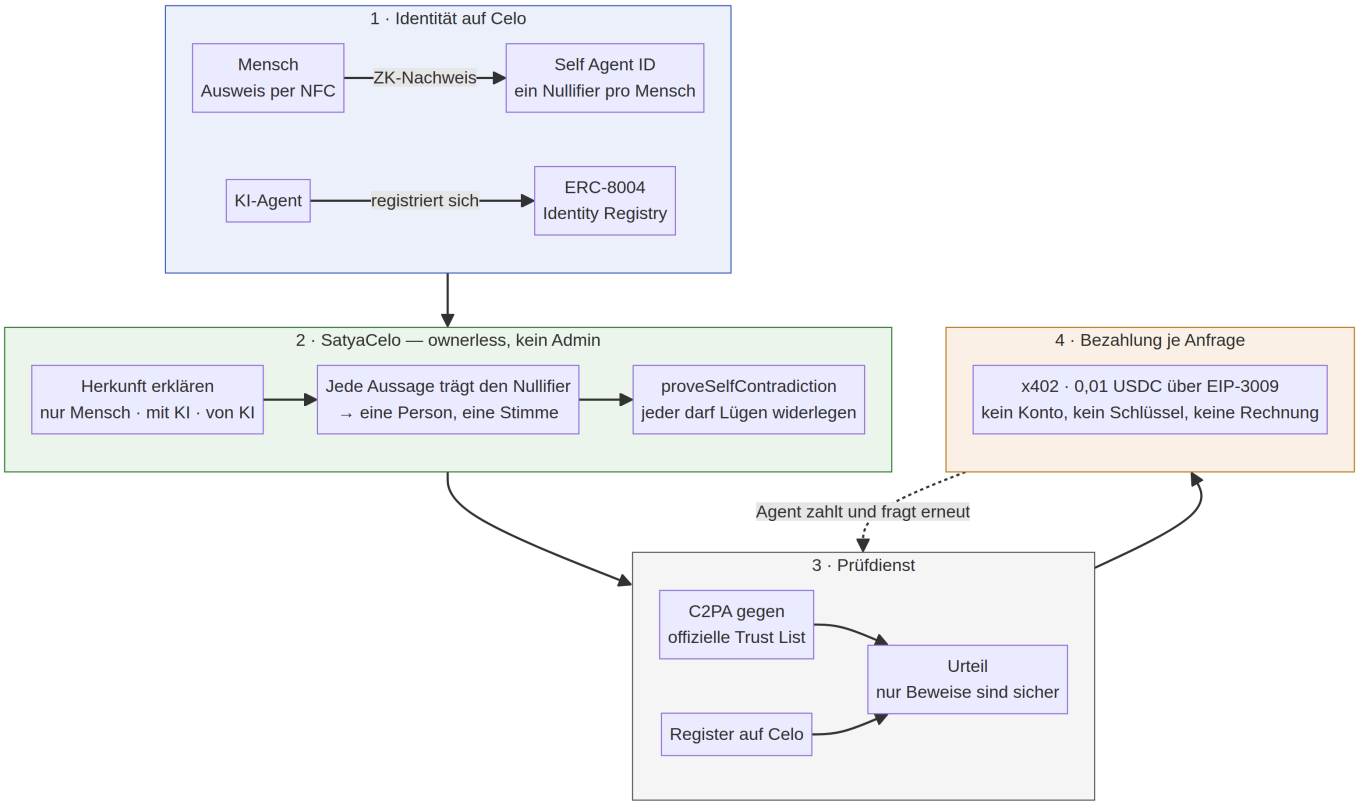
Ein Agent, der wissen will, ob er einer Datei trauen kann, braucht keinen Account und keinen API-Schlüssel:

```
POST /api/x402/verify          → 402, Preis: 0,01 USDC auf celo-sepolia
POST /api/x402/verify          → 200 + Befund + Quittung
  X-PAYMENT: <signierte EIP-3009-Autorisierung>
```

Echter Durchlauf, real abgerechnet:

```
402 Payment Required — 0.01 USDC on celo-sepolia
Guthaben vorher: 19.980000 USDC
→ 200 OK
   verdict  KI_NACHGEWIESEN (sicher)
   proof    C2PA: Signiertes Manifest von OpenAI OpCo, LLC …
   register AI_GENERATED via AGENT_8004
   Zahlung  settled=True
            0xc3f8a7eebc67969f51e6c8b43e329b8e91fa3e118413fc8b4ea76d8b65c8
Guthaben nachher: 19.970000 USDC
```

3. Architektur



Der Vertrag spricht mit zwei bestehenden Celo-Registern und besitzt selbst nichts:

Rolle	Vertrag auf Celo Sepolia
Menschlichkeit + Agentenbindung	Self Agent ID `0x043DaCac8b0771DD5b444bCC88f2f8BBDBEdd379`
Agentenidentität	ERC-8004 `0x8004A818BFB912233c491871b3d84c89A494BD9e`
Bezahlung	x402-Facilitator `api.x402.sepolia.celo.org`, USDC `0x01C5C012…BC44E`

Drei Wege, sich zu erklären

Funktion	Wer	Was der Vertrag prüft
`declareAsHuman`	verifizierter Mensch	Self-Nachweis vorhanden **und** frisch; Nullifier noch nicht für diesen Inhalt verbraucht
`declareAsAgent`	Agent eines verifizierten Menschen	Agent gehört dem Aufrufer; Mensch dahinter wird mitgeführt; darf **nie** „nur Mensch" behaupten
`declareAsAgent8004`	reiner ERC-8004-Agent	Wallet stimmt mit der Registry überein; ohne Mensch dahinter, daher ohne Stimmrecht bei Widersprüchen

Dazu `anchorSeal`: eine EIP-712-signierte Erklärung, die **ein Dritter** einreichen und bezahlen kann. Der Mensch signiert offline, der Dienst trägt die Gaskosten – wichtig, weil sonst jeder Zeuge erst CELO besorgen müsste.

Kosten

Aufruf	Gas	Auf Celo real
`declareAsHuman`	~153 000	Bruchteile eines Cents
`declareAsAgent8004`	129 331 (Tx)	gemessen
`proveSelfContradiction`	~27 000	Betrugsaufdeckung ist billiger als die Lüge
Vertragsgröße	10 016 Byte	weit unter dem Limit

Dass Betrugsaufdeckung **fünfmal günstiger** ist als die Falschaussage, ist Absicht: Wer lügt, zahlt mehr als der, der die Lüge widerlegt.

4. Was bewiesen ist – und was nicht

Satya unterscheidet strikt zwischen **Beweis** und **Indiz**, und sagt „weiß ich nicht", wenn es nichts weiß.

Stufe	Beispiel	Darf entscheiden?
Beweis	C2PA-Signatur, über die offizielle Trust List verifiziert; Erklärung eines verifizierten Menschen	ja
Indiz	unsignierte Metadaten, offene Wasserzeichen, Textähnlichkeit	nein, wird nur angezeigt
Unbestimmt	nichts davon vorhanden	ehrliche Antwort

Gemessen an einem Testkorpus von 22 Fällen mit bekannter Wahrheit:

	Satya	naiver Indizien-Detektor
trifft überhaupt eine Aussage	9 von 22 (41 %)	16 von 22
davon falsch	**1**	**5**
davon unschuldige als KI beschuldigt	0	3

Der naive Detektor antwortet öfter und liegt dabei fünfmal daneben – darunter dreimal gegen einen echten Menschen, etwa beim „echten Foto mit nachträglich eingefügten Stable-Diffusion-Parametern". Satya schweigt in diesen Fällen.

Der eine Fehler ist der interessante. Fall 22: Mallory ist ein verifizierter Mensch und versiegelt einen KI-Text wahrheitswidrig als „ohne KI". Nichts an der Datei verrät das. Satya urteilt sicher und falsch – eine konsistente Lüge einer haftbaren Person ist durch Prüfung des Inhalts nicht aufzudecken.

Genau hier greift Celo. Sobald irgendjemand eine zweite, unvereinbare Aussage derselben Person findet und `proveSelfContradiction` aufruft, markiert der Vertrag beide Aussagen als widerlegt. Dieselbe Messung danach:

	vorher	nach Aufdeckung
sichere Urteile	9	9
davon falsch	1	**0**

Das Register korrigiert sich selbst, ohne dass ein Betreiber eingreift – und der naive Detektor bleibt bei seinen fünf Fehlern, weil ihm niemand widersprechen kann.

Grenzen, offen gesagt:

- Wer eine Datei ohne jeden Nachweis hochlädt, bekommt „unbestimmt". Das ist das Richtige, aber keine Antwort auf die Frage, die viele stellen.
- Ein verifizierter Mensch, der **konsistent** lügt, bleibt unentdeckt, solange er sich nie widerspricht. Satya macht Lügen nachweisbar, nicht unmöglich. Die Aufdeckung setzt voraus, dass jemand die zweite, unvereinbare Aussage findet.
- Die Abdeckung von 41 % ist niedrig. Das ist der Preis dafür, nie zu raten – und sie steigt genau in dem Maß, wie Artikel 50 die Kennzeichnung zur Pflicht macht.
- Self Agent ID ist eine Vertrauensannahme. Fällt sie, fällt die Personenbindung.
- Celo Sepolia ist ein Testnetz; die Self-Nachweise dort stammen aus Mock-Dokumenten.
- Die x402-Abrechnung läuft derzeit über den direkten EIP-3009-Pfad, weil der Settlement-Endpunkt des Celo-Facilitators einen Dashboard-Schlüssel verlangt, der eine Wallet-Signatur im Browser erfordert. Der Verifikationspfad läuft über den Facilitator.

5. Selbst ausprobieren

```
git clone <repo> && cd satya
pip install -r requirements.txt

# Register live auf Celo abfragen – braucht nichts weiter
curl -s https://<host>/api/celo/herkunft/0xd7c2d77c62016c1038466eb73df60a

# Vollständiger Ablauf gegen die Live-Chain
python3 demo/celo_flow.py

# Als Agent eine Prüfung kaufen (braucht Test-USDC)
python3 demo/x402_client.py --url https://<host>

# Dienst lokal starten (Celo + lokales Demo-Register)
./demo/serve.sh 8000
```

Vertragstests:

```
cd contracts && forge test     # 46 Tests, davon 29 für SatyaCelo
```

6. Warum Celo

Nicht austauschbar – drei Dinge gibt es so nur hier:

1. **Self Agent ID** ist der einzige produktive Proof-of-Personhood, der Agenten direkt an einen eindeutigen Menschen bindet. Ohne ihn ist „eine Person, eine Stimme" nicht durchsetzbar.
2. **Gas, das niemanden ausschließt.** Ein Register, in dem Zeugen aussagen, funktioniert nur, wenn Aussagen Bruchteile eines Cents kosten.
3. **x402 mit nativem USDC**, damit ein Agent einen Dienst bezahlen kann, ohne vorher Mensch zu werden.

Quellen

- Sadasivan et al., *Can AI-Generated Text be Reliably Detected?* (arXiv 2303.11156)
- Zhang et al., *Watermarks in the Sand* (arXiv 2311.04378)
- Verordnung (EU) $^{2024}/_{1689}$ (KI-Verordnung), Artikel 50
- C2PA-Spezifikation 2.2 und offizielle Trust List (c2pa.org)
- Celo-Dokumentation: Self Agent ID, ERC-8004, x402